

个人简介

我的研究方向聚焦于深度学习与模型优化,在知识蒸馏与计算机视觉领域有深入探索,并以第一作者在 ICICML 2023 发表相关论文。目前担任深度学习算法工程师,主导公司 AI 智能体基础设施 (daemon / harness / skills / MCP) 从 0 到 1 的建设,同时以 CTO 身份参与创业项目的技术决策与架构设计。我曾任职于微软 (中国) Azure 云架构团队,并在富谙智科技主导数据分析与全栈开发,具备云原生架构、AI 工程化落地及跨团队协作的完整能力。技术栈覆盖 PyTorch、TensorFlow、LangGraph 等主流框架,以及 Claude、Codex、DeepSeek、Multica 等 AI Agent 工具链。期待将学术积累与工程实践结合,在 AI 软件研发的岗位上持续创造价值。

学历

Roux 研究院, 美国东北大学

01.2024 - 06.2025

计算机科学硕士

GPA: 4.0

俄亥俄州立大学, 美国

08.2015 - 06.2019

电气与计算机工程学士

数学辅修

工作

上海深度星能科技有限公司

08.2026 - 至今

深度学习算法工程师

上海

- 超级智能体基础设施 (从 0 到 1): 以 Claude、Codex、DeepSeek 等顶尖模型为推理引擎,采用多模型交叉循环迭代方式从零构建公司自有智能体体系,独立负责 daemon (常驻守护进程: 任务推送、会话续接、审批闸门、崩溃恢复)、harness (分层规则与安全底座)、skills (可复用技能库与按需加载)、MCP (工具与协议接入层) 四大核心部件
- 智能体运行时与协议层: 设计多回合 agent loop、工具调用、上下文压缩与续接、prompt 分层注入,使智能体具备长期稳定运行与跨会话续接能力;并落地生产级 MCP 服务与 8 个首版只读工具,覆盖 service account、多租户边界、审计与 trace 关联、限流、有界并发、故障注入与恢复、kill switch,通过 Claude / Codex 双客户端真实互操作与安全矩阵验证
- AI 研发舰队: 熟练编排 Paseo、Multica、Metathinking、VS Server、Sol-Pi 等工具链,组建“多智能体 × 多模型 × 多角色”研发流水线,覆盖架构评审、实现、验证与发布;以任务为单一真值源定义角色分工、证据链与评审门禁 (评审者 ≠ 作者),使 agent 产出可审计、可交接、可复盘
- Token 效率优化与规模化交付: 建立四桶 token 计量 (新输入 / 输出 / 缓存读 / 缓存写) 与任务级成本台账,通过模型路由、缓存前缀对齐、上下文分层与按需加载、终端输出确定性压缩等手段持续优化 token 利用率;单个项目在 9 个自然日内协同交付 11 个 PR、约 9,500 行代码变更,其中测试代码占比 49%
- 数字化平台与 AI 专家诊断: 为公司项目搭建数字化数据分析平台,打通工业 PLC 小时数据、供水产销差与 DMA 分区、项目情报等多源异构数据,以自然语言驱动“取数—分析—成稿”全流程并交付 AI 专家诊断报告;代表成果包括供水管网漏损与 DMA 产销差分析、在线水表异常识别与换表计划优化、供水与水利项目情报 CRM 方案
- 代表公司参加 2026“数擎杯”数据开发利用赛道 (队长 / 数据算法负责人): 统筹 5 人团队的目标拆解与节点排期;主导“水脉智擎”水务项目情报数据产品的算法设计,基于经授权的公共数据 (5,506 条授权运营公共数据资源目录) 与多源融合,负责文档结构化抽取、跨源实体归一、商机分级评分、金标数据集与模型评测,实现“跨平台合并 + 来源可核验 + 阶段全链追踪 + 智能评分”的闭环

数字工厂 (副业)

01.2026 - 至今

联合创始人 & CTO

上海

- 主导构建基于多智能体协作的分布式 AI 工厂系统,负责整体技术架构设计与 AI 模型编排
- 设计并落地混合云-本地推理架构,整合 Claude Code、DeepSeek V4 Pro、Qwen (蒸馏 Opus 4.7) 等多型号大模型,通过 Ollama 实现本地低成本推理,优化响应速度与算力成本

- 基于 Multica + OpenClaw 搭建多 Agent 协作框架，调度 Hermes、QoderWake 等数字员工并行处理复杂任务，实现游戏设计业务的自动化流水线
- 从 0 到 1 组建技术体系，覆盖 AI 推理、任务编排、多模型路由等核心模块
- 业务从游戏设计拓展至团购等多条线，系统具备良好的可迁移性与横向扩展能力

富诺智信息技术有限公司

12.2021 - 07.2022

数据分析研发师

上海

- 在敏捷开发环境中以全栈工程师角色负责核心库 FNZOneX 的研发与改进
- 为顾问 (Adviser) 组设计新的用户组结构，并调整 Alchemist 依据用户权限矩阵生成的定义脚本
- 将第三方 Addressy 地址查询 API 集成至网站全部地址字段
- 为多套开发/测试环境编写并维护运行期 SQL 脚本集
- 通过浏览器开发者工具 (Elements / Console / Sources / Network) 定位 JavaScript 报错，并使用 Visual Studio 调试模式排查 aspx/aspx.vb 异常
- 配置、修改并共享 IIS 服务器设置，用于开发与演示环境
- 与全球 IT 部门及跨团队同事协作，处理跨区域权限与职责边界问题
- 解决测试人员反馈的阻塞与发布问题，并在功能评审前完成自测与测试流程制定

上海微创软件股份有限公司 (微软大中华区)

10.2019 - 12.2021

云架构工程师 & 技术顾问

上海

- 负责微软云 Azure 四个产品 (Monitor、Log Analytics、Automation、Application Insights) 的技术支持
- 定制警报配置、查询搜索、数据采样与多类性能计数器采集
- 捕获并分析 NetMon、ProcMon 与 Fiddler 跟踪，定位代理、混合辅助角色与门户问题；通过 Azure 仪表板、度量资源管理器与工作簿完成数据可视化
- 使用 Visual Studio / VS Code 在 .Net / .Net Core / Java / Python / JavaScript 中调试 Application Insights SDK 配置脚本
- 参与设计、修改与调试 PowerShell / Python / PS 工作流与图形化 Runbook、DSC 配置；就合作伙伴集成与工作区方案 (更新管理、虚拟机自动启停、更改跟踪、资源清册) 提供建议
- 对接 Adobe、Intel、Amazon 等关键客户，专责处理高风险与长期未决案例升级
- 负责上海、无锡、北京三地共 12 人团队的技术管理与协调，并处理跨团队职责边界争议
- 与技术负责人及协作技术顾问共同开展案例分析、技术面试与团队规划

项目

工业 AI 数据底座与业务系统 AI 化

06.2026 - 07.2026

高级 AI 开发工程师

群贤集团

- 设计并构建工业级 AI 数据底座，整合多源异构生产数据 (桂林工厂 4×42MVA 矿热炉锰合金产线)，负责模型训练与性能优化
- 主导 ERP 系统智能化改造，将 AI 能力嵌入供应链管理与资源配置核心流程
- 推动 OA 平台 AI 化升级，集成智能审批、知识问答与流程自动化，显著提升办公效率

银河卷积神经网络的数据集蒸馏

09.2024 - 12.2025

导师: Tala Talaei Khoei

NEU

- 通过使用最新 Galaxy Zoo 数据集的提取和整理版本，在星系形态分类等任务中展现出卓越的性能
- 仔细调整统计显著性阈值以确定验证损失趋势，以优化性能
- 使用 STM (Self-Adaptive Trajectory Matching, 自适应轨迹匹配) 防止过拟合并加速学习过程
- 提供更高的分类准确性和更高效的训练，同时减少类别失衡并提高整体数据质量

深度强化学习的知识蒸馏

07.2023 - 09.2023

导师: Mark Vogelsberger

MIT

- 通过 pytorch 提供的深度 Q 网络搭建深度强化学习的教师与学生模型
- 在 Gymnasium 提供的 CartPole 环境中进行实验比较
- 通过改变温度和回归次数等参数来测试知识蒸馏的效率
- 在 CartPole, MountainCar, Acrobot, LunarLander and Pendulum 环境中比较不同的马可夫决策过程

- 在更复杂的深度回归 Q 网络中实现知识蒸馏
- 本项目的研究成果已形成学术论文，发表于机器学习顶级会议 ICICML 2023:
<https://doi.org/10.1109/ICICML60161.2023.10424889>

毕业设计：太阳能电池板检测仪

01.2019 - 04.2019

导师: *Haskell Jac Fought*

OSU

- 设计并修改软件部分的需求，特征和行为流程图
- 在 Android Studio 上设计，编程并测试蓝牙串行通讯模块
- 从 Arduino 机械码转换已有代码至安卓

AEV 设计，搭建与调试

01.2016-05.2016

导师: *Lauren Corrigan*

OSU

- 通过 Arduino 集成开发编译器编程
- 用 Solid Works 设计 Arduino 的部件，精准控制其尺寸和形状
- 测试并记录 Arduino 的表现，控制变量以提升其空气动力效率

实习 & 兼职

Roux 研究院

01.2025 - 05.2025

机器学习助教

美国

- 辅导学生了解各类机器学习模型及相关技巧
- 与教授讨论课程分配；在办公时间答疑并批阅课程项目

俄亥俄州立大学电气与计算机工程系实验室

09.2018 - 12.2018

实验助教 & 阅卷人

美国

- 实验期间指导学生练习 TI MSP430 系列微控制器编码
- 批改每周测验与实验报告

华虹计通

05.2018 - 07.2018

软件研发工程师

上海

- 学习自动售检票 (AFC) 系统的系统架构、数据流设计、运作原则与编码规范
- 改进西安地铁 1 至 4 号线地铁 UI 交互界面并更新最新地铁线路数据
- 完成数据库由 Oracle SQL 向 DB2 的迁移

华信能源

05.2017 - 07.2017

信息系统工程师

上海

- 改进公司前端 OA 系统，新增人性化排班表并与公司 App (Android / iOS) 打通
- 设计 Access VBA 宏指令集，自动核算各部门电话账单并支持筛选、报表统计与导出

技能

编程语言

Python, C#, Java, C++, Golang, Shell, JavaScript, M, VBA, VHDL

机器学习框架

PyTorch, TensorFlow, Keras, Scikit-learn, LangGraph

模型与 AI 工具

Claude, Codex, DeepSeek, Qwen, Pi, Wan, Flux, Kling, Seedance

智能体框架

MCP Server, Agent Runtime / daemon, harness 规则编排, skills 技能库

Agent 工具链

Multica, Metathinking, Paseo, Sol-Pi, HiClaw, PaperClips, Hermes

智能体工程

token 成本治理, 模型路由, prompt cache 对齐, 上下文分层与压缩, 多智能体编排, 模型评测

模型优化技术

知识蒸馏 (Knowledge Distillation), 模型量化, 剪枝, 推理加速

数据库

Microsoft SQL, KQL, MySQL, MongoDB, SQLite

云平台与架构

Azure, AWS, 分布式系统, 微服务

开发工具

VS, VS Code, Git, Docker, SQL Server, Kusto, TailScale, Coder Workspace

硬件基础

Arduino, Multiplexers, PLDs, Clocked Sequential Circuits, VLSI

课程

计算机	机器学习, 数据库管理系统, 算法, 云计算, 软件开发与设计, 操作系统, 计算机体系结构与设计, 计算机组成与嵌入式系统
电气	模拟系统与电路, 信号与系统, 数字逻辑, 微控制器, 半导体电子器件, 光学工程, 反馈控制系统, 高级数字设计, VLSI 数字信号处理系统
数学	科学家与工程师微积分, 线性代数, 高等数学, 数值分析, 偏微分方程
其他	工程经济决策, 工程伦理, 概率论与数理统计

兴趣爱好

工作之外，我是个动静皆宜的人。动的方面，我热爱匹克球和羽毛球，享受球场上快节奏对抗和团队配合的默契；静的方面，我是密室逃脱、剧本杀和桌游的资深爱好者，喜欢在沉浸式剧情和烧脑推理中切换思维、体验不同视角。这些爱好让我深信：好的 AI 产品也像一场精心设计的游戏——需要对用户心理的深度共情，以及对细节体验的极致打磨。期待未来团建时和大家来一场酣畅淋漓的切磋。